



# Modelo Auto Regressivo (AR) - Gráfico PACF

# Aula	25
<input checked="" type="checkbox"/> Ready	<input checked="" type="checkbox"/>
<input checked="" type="checkbox"/> Finished	<input checked="" type="checkbox"/>
≡ Ciclos	Ciclo 03: Algoritmos Estatísticos

## Objetivo da Aula:

- ☐ Ferramentas
- ☐ Função Autocorrelação Parcial ( PACF )

## Conteúdo:

### ▼ 1. Ferramentas

1. A ordem pode ser escolhida com base na **Função de Autocorrelação Parcial (PACF)**.

### ▼ 2. Função Autocorrelação Parcial (PACF)

A **Função de Autocorrelação Parcial (PACF)** mede a **correlação direta** entre um valor da série temporal e seus valores defasados, removendo a influência das observações intermediárias.

Em outras palavras, enquanto a **Autocorrelação (ACF)** mede a correlação entre um valor e todas as suas defasagens, a **PACF** isola o efeito de cada lag separadamente, eliminando influências indiretas de lags anteriores.

## ▼ 2.1. Como a PACF é calculada?

A PACF é determinada resolvendo um sistema de equações chamado equações de Yule-Walker, que ajustam um modelo autorregressivo (AR) e calculam os coeficientes da relação direta entre um valor da série e suas defasagens.

Seja  $X_t$  uma série temporal, a PACF mede o impacto direto entre  $X_t$  e  $X_{t-k}$  desconsiderando os efeitos de  $X_{t-1}, X_{t-2}, \dots, X_{t-(k-1)}$

## ▼ 2.2. Como PACF é usada para determinar a ordem do modelo AR?

A ordem  $p$  do modelo  $AR(p)$  corresponde ao número de lags significativos na PACF.

### 1. Gerar o gráfico da PACF

- No gráfico da PACF, o eixo X representa o número de defasagens (lags), e o eixo Y representa a autocorrelação parcial.
- A linha pontilhada no gráfico indica o nível de significância estatística.

### 2. Identificar o lag onde a PACF se torna insignificante

- No modelo  $AR(p)$ , a PACF corta bruscamente (ou seja, cai para valores próximos de zero) após  $p$  defasagens.
- O primeiro lag onde a PACF se torna insignificante indica a ordem  $p$  ideal.

## ▼ 2.3. Exemplo prático

Suponha que tenhamos um gráfico da PACF para uma série temporal e observamos que os primeiros dois lags têm valores significativamente diferentes de zero, mas os lags seguintes não são estatisticamente significativos, como o exemplo abaixo:

### ▼ 2.3.0. Código em Python para senoide

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.graphics.tsaplots import plot_pacf
```

```

# Gerar série temporal senoidal
np.random.seed(42)
n = 200 # Número de pontos
t = np.arange(n)
T = 20 # Período da senoide
series = np.sin(2 * np.pi * t / T) + np.random.normal(scale=0.1, size=n)

# Criar DataFrame
dates = pd.date_range(start="2023-01-01", periods=n, freq="D")
senoidal_series = pd.Series(series, index=dates)

# Plotar série temporal
plt.figure(figsize=(12, 5))
plt.plot(senoidal_series, label="Série Senoidal")
plt.title("Série Temporal Senoidal")
plt.xlabel("Tempo")
plt.ylabel("Valor")
plt.legend()
plt.grid()
plt.show()

# Plotar PACF
plt.figure(figsize=(8, 5))
plot_pacf(senoidal_series, lags=40, alpha=0.05, method='ywm')
plt.title("Função de Autocorrelação Parcial (PACF)")
plt.grid()
plt.show()

```

### ▼ 2.3.1. Código em Python

```

# Reimportar bibliotecas após reset do estado de execução
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.graphics.tsaplots import plot_pacf

# Gerar uma série temporal simulada com um processo AR(2)
np.random.seed(42)

```

```

n = 100
ar_params = [0.7, -0.3] # Coeficientes do modelo AR(2)
noise = np.random.normal(0, 1, n)

# Criar a série AR(2)
series = np.zeros(n)
series[0], series[1] = noise[0], noise[1]


for t in range(2, n):
    series[t] = ar_params[0] * series[t - 1] + ar_params[1] * series[t - 2]

# Criar DataFrame
dates = pd.date_range(start="2023-01-01", periods=n, freq="D")
series_df = pd.Series(series, index=dates, name="AR(2) Series")


# Plotar a série temporal
plt.figure(figsize=(12, 6))
plt.plot(series_df, label="Série Temporal AR(2)")
plt.title("Série Temporal Simulada (AR(2))")
plt.xlabel("Data")
plt.ylabel("Valor")
plt.legend()
plt.grid()
plt.show()

# Plotar PACF
plt.figure(figsize=(12, 6))
plot_pacf(series_df, lags=20, alpha=0.05)
plt.title("Função de Autocorrelação Parcial (PACF) - AR(2)")
plt.show()

```



### ▼ 2.3.2. Gráfico PACF



Os gráficos exibem:

1. **Série Temporal Simulada (AR(2)):** Uma série temporal gerada a partir de um modelo autorregressivo de segunda ordem (AR(2)), onde cada valor depende dos dois valores anteriores e de um termo de erro aleatório.
2. **Função de Autocorrelação Parcial (PACF):** O gráfico PACF mostra quais defasagens ( $p$ ) têm correlação significativa com a série temporal, ajudando a identificar a ordem do modelo AR

apropriado. No caso de um  $AR(2)$ , esperamos que as defasagens 1 e 2 sejam estatisticamente significativas, enquanto as demais não.

Neste caso, o modelo mais apropriado seria um  **$AR(2)$** , pois a PACF corta após o segundo lag. Se a PACF cortasse após o terceiro lag, o modelo apropriado seria  **$AR(3)$** .